

Projet d'économétrie

durée en emploi (France)

Eric Lin

L3 Economie-Gestion Parcours Ingénierie Economique

Introduction	2
Partie 1 : Statistiques descriptives	3
1. Description de la base de données	3
2. Sélection de l'échantillon de travail	5
Pour la variable expliquée :	5
Pour les variables explicatives :	5
3. Statistiques descriptives univariées	11
i) Pour la variable expliquée (statistiques, graphiques) :	11
ii) Pour les variables explicatives :	13
Pour les variables d'intérêt :	13
Pour les variables de contrôle :	14
4. Statistiques descriptives bivariées	19
Avec les variables d'intérêt :	19
Avec les variables de contrôle :	21
PARTIE 2 : Estimation du modèle linéaire multiple	26
1. Présentation du modèle à estimer et le modèle estimé :	26
Le modèle à estimer :	26
Le modèle estimé :	26
2. Résultats des estimations du modèle MCO :	27
3. Commentaire des résultats :	31
Test de significativité globale de la régression ou test de Fisher	31
Test de significativité de chacun des coefficients	32
4. Tests de détection de l'hétéroscédasticité :	34
Test de Goldfeld-Quandt	35
Test de Gleisjer	37
Test de Breusch-Pagan	39
Conclusion :	40

Introduction

La durée en emploi constitue un indicateur fondamental du fonctionnement du marché du travail. Elle permet d'évaluer la stabilité professionnelle des individus, la qualité des emplois, ainsi que la sécurité économique des travailleurs. Comprendre les facteurs qui influencent la durée d'un emploi est essentiel car cela reflète directement la dynamique de l'emploi.

Ici, nous allons analyser la base de données de l'enquête « Génération 98 » du CEREQ, contenant les observations de sortants de formation initiale en 1998.

L'objectif principal est d'identifier les déterminants individuels et professionnels qui influencent la probabilité pour un individu de conserver son emploi sur une période donnée. La durée en emploi est influencée par un ensemble de facteurs tels que l'âge, le niveau d'éducation, le secteur d'activité, le salaire, le genre,...

Nous allons effectuer une analyse économétrique, où nous chercherons à estimer l'impact de ces différents facteurs sur la durée en emploi en utilisant des modèles de régression. Cette analyse permettra d'identifier les profils les plus exposés à la précarité de l'emploi et d'apporter des éléments de compréhension sur les mécanismes qui favorisent la stabilité professionnelle. Les résultats de ce travail pourront être utilisés pour approfondir l'étude de la mobilité de l'emploi.

Partie 1 : Statistiques descriptives

1. Description de la base de données

Nous avons une base composé de **5999 observations** où l'on cherche à expliquer notre **variable expliquée** : *duree*, la durée en emploi grâce aux différentes **variables explicatives** :

- *sex* : sexe
- *age* : âge en années des individus
- *nes16* : catégorie socioprofessionnelle de l'employeur en 16 postes / secteur d'activité
- *nivagr* : niveau de diplôme agrégé (plus haut niveau de diplôme obtenu)
- *cspe* : catégorie socioprofessionnelle au premier emploi
- *salcalc* : salaire horaire net prime incluse
- *rural* : entreprise rurale (ou non)
- *nbent* : nombre total d'entreprises différentes dans lequel l'individu a travaillé
- *taille* : taille de l'entreprise par tranche
- *cens* : situation professionnelle (chômage/ non emploi ou toujours en emploi)

On prendra ici l'âge et le salaire comme **variable d'intérêt** en supposant que ces variables auront un impact plus important sur la durée et nous allons prendre en **variable de contrôle** : *nes16*, *cspe*, *nbent*, *sex*, *nivagr*, *rural*, *taille*, *cens*.

Effet attendu :

- **durée-âge** : Nous supposons que l'âge joue un rôle dans la durée possible passé dans une entreprise. En effet, une personne plus âgée aura une plus grande probabilité d'être restée dans une entreprise sur une longue durée par rapport à un jeune diplômé. On ne peut néanmoins pas généraliser car il n'y a pas de lien de causalité.
- **durée-salaire** : Nous supposons qu'il y a un lien entre la durée dans une entreprise et le salaire perçu car l'ancienneté dans une entreprise joue souvent un rôle dans les augmentations et les promotions. Cela signifie que l'on suppose un potentiel lien positif entre la durée et le salaire.
- **durée-sexe** : Nous supposons que la durée d'emploi peut varier selon le sexe. En général, les hommes ont tendance à avoir une ancienneté plus longue que les femmes, en raison d'interruptions de carrière (maternité, responsabilités familiales) ou de possibles discriminations dans l'accès à des postes stables et à la promotion.
- **durée-catégorie socioprofessionnelle de l'employeur en 16 postes** : Nous supposons que la durée d'un contrat peut varier selon le secteur d'activité et le

contexte socio-économique. En général, certains postes offrent plus de stabilité et d'ancienneté, tandis que d'autres peuvent être plus précaires.

- **durée-niveau de diplôme agrégé** : Nous attendons une relation positive entre la durée d'emploi en mois et le niveau de diplôme car les personnes plus diplômées ont souvent des emplois plus stables et des opportunités de carrière plus longues bien qu'il soit difficile de généraliser cet effet car cela dépend des secteurs.
- **durée-catégorie socioprofessionnelle au premier emploi** : Nous supposons que la durée d'emploi peut dépendre de la catégorie socioprofessionnelle occupée lors du premier emploi. En général, les individus ayant commencé dans des postes plus qualifiés ou stables tendent à avoir une ancienneté plus longue.
- **durée-milieu de l'entreprise** : Nous supposons que la durée d'emploi peut varier selon que l'entreprise se situe en zone rurale ou urbaine. En général, les entreprises rurales peuvent offrir des emplois plus stables mais avec moins d'opportunités de carrière ce qui peut inciter l'individu à changer d'entreprise.
- **durée-nombre totale d'entreprises différentes dans lequel l'individu a travaillé** : Nous supposons que la durée d'emploi est liée au nombre total d'entreprises dans lesquelles une personne a travaillé. En général, plus une personne change fréquemment d'entreprise, plus sa durée d'emploi dans chaque entreprise est courte.
- **durée-taille de l'entreprise par tranche** : Nous supposons que la durée d'emploi peut varier selon la taille de l'entreprise. En général, les salariés des grandes entreprises ont tendance à rester dans l'entreprise en raison de la stabilité et des différentes opportunités de carrière.
- **durée-situation professionnelle** : Nous supposons qu'un individu étant en emploi au moment de l'enquête aura une durée d'emploi potentiellement plus longue qu'un individu sans emploi au moment de l'enquête bien qu'il n'y ait pas de réel lien causal.

2. Sélection de l'échantillon de travail

Tableaux de fréquences pour les variables quantitatives et la distribution pour les variables quantitatives :

Pour la variable expliquée :

duree						Durée en emploi
Type: Numeric (byte)						
Range: [1,72]			Units: 1			
Unique values: 72			Missing .: 0/5,999			
Mean: 29.842						
Std. dev.: 19.4033						
Percentiles:	10%	25%	50%	75%	90%	
	6	12	27	46	59	

Dans notre variable expliquée **duree**, la durée de l'emploi en mois on peut voir qu'il y a 5999 valeurs sur 5999, il n'y a pas de valeurs manquantes ni de valeurs aberrantes.

Pour les variables explicatives :

age						Age en années
Type: Numeric (byte)						
Range: [26,46]			Units: 1			
Unique values: 21			Missing .: 9/5,999			
Mean: 31.8421						
Std. dev.: 2.51171						
Percentiles:	10%	25%	50%	75%	90%	
	29	30	31	33	35	

Dans notre variable d'intérêt **age**, on peut voir qu'il y a 5990 valeurs sur 5999 donc on enlève les valeurs manquantes (9) et il n'y a pas de valeurs aberrantes.
On se retrouve donc avec 5990 observations.

salcalc	salaire horaire				
Type: Numeric (float)					
Range: [.25,42]			Units: .001		
Unique values: 1,169			Missing .: 133/5,990		
Mean: 6.89383					
Std. dev.: 3.38733					
Percentiles:	10%	25%	50%	75%	90%
	2.7	5.1	6.309	8.45	10.833

Dans notre variable d'intérêt **salaire** (horaire net prime incluse), on peut voir qu'il y a 5857 valeurs sur 5990 donc on enlève les valeurs manquantes (133).
On se retrouve donc avec 5857 observations.

salaire horaire				
Percentiles	Smallest			
1%	1.5	.25		
5%	2.489	.3		
10%	2.7	.3	Obs	5,857
25%	5.1	.45	Sum of wgt.	5,857
50%	6.309	Largest	Mean	6.89383
			Std. dev.	3.387334
75%	8.45	30		
90%	10.833	32	Variance	11.47403
95%	13	40	Skewness	1.616641
99%	18	42	Kurtosis	9.891361

Il y a des valeurs aberrantes donc on enlève les 1% les plus bas et 1% les plus hauts (109).
On se retrouve donc avec 5748 observations.

```
. keep if inrange(salcalc, r(p1),r(p99))
(109 observations deleted)
```

```
. sum salcalc, d
```

Salaire horaire				
Percentiles	Smallest			
1%	2.2	1.5		
5%	2.5	1.5		
10%	2.783	1.5	Obs	5,748
25%	5.139	1.5	Sum of wgt.	5,748
50%	6.3	Largest	Mean	6.795497
			Std. dev.	2.979948
75%	8.342	18		
90%	10.6	18	Variance	8.880091
95%	12.753	18	Skewness	.8347324
99%	15.75	18	Kurtosis	3.914814

. tab sex

sexe	Freq.	Percent	Cum.
Femme	2,588	45.02	45.02
Homme	3,160	54.98	100.00
Total	5,748	100.00	

Dans notre variable de contrôle **sexe**, on peut voir qu'il y a 5748 valeurs sur 5748, il n'y a pas de valeurs manquantes ni de valeurs aberrantes.

CS de l'employeur	Freq.	Percent	Cum.
Agriculture	141	2.45	2.45
Commerce	875	15.22	17.68
Construction	389	6.77	24.44
Educ, Sante, Admin.	1,594	27.73	52.17
IAA	243	4.23	56.40
Industrie	1,035	18.01	74.41
Nr	6	0.10	74.51
Serv. aux part.	512	8.91	83.42
Service aux ent.	953	16.58	100.00
Total	5,748	100.00	

Dans notre variable de contrôle **CS de l'employeur** en 16 postes / secteur d'activité, on peut voir qu'il y a 5748 valeurs sur 5748, il y a une valeur "Nr" pour non renseigné qui représente 0.1% de l'échantillon donc nous avons décidé de la supprimer (6), il n'y a pas de valeurs aberrantes.

On se retrouve donc avec 5742 observations.

CS de l'employeur	Freq.	Percent	Cum.
Commerce	875	15.24	15.24
Construction et Agriculture	530	9.23	24.47
Educ, Sante, Admin.	1,594	27.76	52.23
Industrie et IAA	1,278	22.26	74.49
Serv. aux part.	512	8.92	83.40
Service aux ent.	953	16.60	100.00
Total	5,742	100.00	

Dans notre variable **nes16**, CS de l'employeur, on regroupe ici industrie avec IAA (industrie agro-alimentaire) et construction avec agriculture pour que les effectifs des modalités soient proche de 10% et avoir des modalités plus significatives bien que la construction et l'agriculture soient des secteurs totalement différents.

. tab nivagr_1

Plus haut niveau de diplôme obtenu	Freq.	Percent	Cum.
Baccalauréat	1,362	23.72	23.72
Brevet ou aucun diplôme	309	5.38	29.10
CAP,BEP	2,093	36.45	65.55
L2,BTS,DUT	988	17.21	82.76
L3 ou plus	990	17.24	100.00
Total	5,742	100.00	

Dans notre variable de contrôle **niveau de diplôme** agrégé (plus haut niveau de diplôme obtenu), on peut voir qu'il y a 5742 valeurs sur 5742, il n'y a pas de valeurs manquantes ni de valeurs aberrantes.

Plus haut niveau de diplôme obtenu	Freq.	Percent	Cum.
Baccalauréat, Brevet ou aucun diplôme	1,671	29.10	29.10
CAP,BEP	2,093	36.45	65.55
L2,BTS,DUT	988	17.21	82.76
L3 ou plus	990	17.24	100.00
Total	5,742	100.00	

On a regroupé les modalités Baccalauréat et Brevet ou aucun diplôme pour avoir des modalités plus significatives et avoir ainsi des modalités supérieur à 10%.

. tab cspe_1

CSP au premier emploi	Freq.	Percent	Cum.
Employe	1,958	34.10	34.10
Ouvrier non qualifié	863	15.03	49.13
Ouvrier qualifié	980	17.07	66.20
P.lib,cadre,inge,prof.	817	14.23	80.42
Technicien,PI	1,124	19.58	100.00
Total	5,742	100.00	

Dans notre variable de contrôle **CSP au premier emploi**, on peut voir qu'il y a 5742 valeurs sur 5742, il n'y a pas de valeurs manquantes ni de valeurs aberrantes.

Travaillez vous dans une entreprise rurale ?	Freq.	Percent	Cum.
Non	4,637	80.76	80.76
Oui	1,105	19.24	100.00
Total	5,742	100.00	

Dans notre variable de contrôle **rural** (entreprise rurale), on peut voir qu'il y a 5742 valeurs sur 5742, il n'y a pas de valeurs manquantes ni de valeurs aberrantes.

Nombre total d'entrepris es différente s dans lequel l'individu a travaillé	Freq.	Percent	Cum.
1	1,642	28.60	28.60
2	1,703	29.66	58.25
3	1,237	21.54	79.80
4	582	10.14	89.93
5	320	5.57	95.51
6	140	2.44	97.94
7	69	1.20	99.15
8	29	0.51	99.65
9	12	0.21	99.86
10	7	0.12	99.98
12	1	0.02	100.00
Total	5,742	100.00	

Dans notre variable de contrôle **nbent**, nombre total d'entreprises différentes dans lequel l'individu a travaillé on peut voir qu'il y a 5742 valeurs sur 5742, il n'y a pas de valeurs manquantes mais il y a des valeurs extrêmes, les 4 premières modalités représentent presque 90% de la distribution tandis que les 4 derniers représentent moins de 1% de la distribution. On va décider par la suite de regrouper les valeurs extrêmes pour avoir une modalité plus importante.

taille	Freq.	Percent	Cum.
50-500	1,674	29.15	29.15
500 et +	983	17.12	46.27
Nsp	194	3.38	49.65
moins de 10	1,414	24.63	74.28
10 à 50 employés	1,477	25.72	100.00
Total	5,742	100.00	

Dans notre variable de contrôle **taille** (taille de l'entreprise par tranche), on peut voir qu'il y a 5742 valeurs sur 5742, il y a une valeur "Nsp" pour ne sais pas qui représente 3.38% de l'échantillon donc nous avons décidé de la supprimer (194), il n'y a pas de valeurs aberrantes. On se retrouve donc avec 5548 observations.

taille	Freq.	Percent	Cum.
10 à 50 employés	1,477	26.62	26.62
50-500	1,674	30.17	56.80
500 et +	983	17.72	74.51
moins de 10	1,414	25.49	100.00
Total	5,548	100.00	

. tab cens

Etes vous en emploi ?	Freq.	Percent	Cum.
Non	1,098	19.79	19.79
Oui	4,450	80.21	100.00
Total	5,548	100.00	

Dans notre variable de contrôle **situation professionnelle** (cens), on peut voir qu'il y a 5548 valeurs sur 5548 donc il n'y a pas de valeurs manquantes.


Nombre d'entreprises différentes dans lequel l'individu a travaillé	Freq.	Percent	Cum.
1	1,590	28.66	28.66
2	1,646	29.67	58.33
3	1,196	21.56	79.88
4	562	10.13	90.01
5	305	5.50	95.51
6 ou plus	249	4.49	100.00
Total	5,548	100.00	

On a fusionné les modalités supérieur ou égale 6 de la variable de contrôle **nombre d'entreprises** car nous préférons les garder sans pour autant fausser la régression avec des valeurs aberrantes.

3. Statistiques descriptives univariées

i) Pour la variable expliquée (statistiques, graphiques) :

La variable expliquée durée, (durée de l'emploi en mois) est continue.



. sum duree, detail

duree				
Percentiles		Smallest		
1%	1	1		
5%	3	1		
10%	6	1	Obs	5,548
25%	12	1	Sum of wgt.	5,548
50%	28		Mean	29.92916
		Largest	Std. dev.	19.32646
75%	46	71		
90%	59	71	Variance	373.512
95%	63	71	Skewness	.2758459
99%	66	71	Kurtosis	1.846738

.

. sum Induree, detail

Induree					
Percentiles		Smallest			
1%	0	0			
5%	1.098612	0			
10%	1.791759	0	Obs	5,548	
25%	2.484907	0	Sum of wgt.	5,548	
50%	3.332205		Mean	3.07775	
		Largest	Std. dev.	.9392286	
75%	3.828641	4.26268			
90%	4.077538	4.26268	Variance	.8821503	
95%	4.143135	4.26268	Skewness	-1.075091	
99%	4.189655	4.26268	Kurtosis	3.798818	

On suppose qu'utiliser la variable durée est préférable à utiliser le log de durée.

. sktest Induree

Skewness and kurtosis tests for normality

Variable	Obs	Pr(skewness)	Pr(kurtosis)	Joint test	
				Adj chi2(2)	Prob>chi2
Induree	5,548	0.0000	0.0000	656.18	0.0000

. sktest duree

Skewness and kurtosis tests for normality

Variable	Obs	Pr(skewness)	Pr(kurtosis)	Joint test	
				Adj chi2(2)	Prob>chi2
duree	5,548	0.0000	0.0000	.	.

.

Shapiro-Wilk W test for normal data

Variable	Obs	W	V	z	Prob>z
salcalc	5,548	0.95145	144.295	13.087	0.00000
lnsalcalc	5,548	0.96961	90.332	11.854	0.00000

Note: The normal approximation to the sampling distribution of W' is valid for $4 \leq n \leq 2000$.

Les deux variables ne suivent pas une loi normale.

On choisira la variable qui se rapproche le plus de la distribution d'une loi normale après avoir comparé le skewness (le plus proche de 0) et le kurtosis (le plus proche de 3) des deux variables. Par conséquent, dans les sum,d de ces deux variables on peut voir que pour durée, le skewness = 0,2758 tandis que le skewness de Induree = -1,0751. Pour le kurtosis duree = 1,8467 et Induree = 3,7988.

La variable durée est relativement plus symétrique car plus proche de 0 que Induree donc pour la suite de l'étude on prendra la variable duree.


ii) Pour les variables explicatives :

Pour les variables d'intérêt :

Pour l'âge (age) :

```
. sum age, d
```

Age				
Percentiles		Smallest		
1%	27	26		
5%	29	26		
10%	29	27	Obs	5,548
25%	30	27	Sum of wgt.	5,548
50%	31		Mean	31.81687
		Largest	Std. dev.	2.461308
75%	33	44		
90%	35	44	Variance	6.058039
95%	36	44	Skewness	1.006861
99%	39	46	Kurtosis	4.753244




L'échantillon est concentré sur des individus ayant la trentaine ce qui suggère un échantillon d'individus assez jeune. La moyenne d'âge est à 31,8 avec un écart type de 2.46 ce qui montre bien cette concentration.

Pour le salaire horaire net prime incluse (salcalc) :

```
. sum salcalc, d
```

salaire horaire net prime incluse				
Percentiles		Smallest		
1%	2.2	1.5		
5%	2.5	1.5		
10%	2.8	1.5	Obs	5,548
25%	5.139	1.5	Sum of wgt.	5,548
50%	6.35		Mean	6.826092
		Largest	Std. dev.	2.968632
75%	8.3695	18		
90%	10.667	18	Variance	8.812776
95%	12.753	18	Skewness	.8392364
99%	15.75	18	Kurtosis	3.93357




Pour la variable salaire horaire net prime incluse, nous avons 5548 observations dans notre échantillon. La moyenne des salaires est à 6.82 euros de l'heure, l'écart-type est de 2.96 indiquant une certaine variabilité dans la répartition.

Pour les variables de contrôle :

Pour le sexe (sex) :

tab sex


sex	Freq.	Percent	Cum.
Femme	2,467	44.47	44.47
Homme	3,081	55.53	100.00
Total	5,548	100.00	



La distribution suggère que la tranche 'Homme' représente une part un peu plus grande de l'échantillon, environ 55,53%.

Pour la catégorie socioprofessionnelle de l'employeur/secteur d'activité (nes16) :

Secteur d'activité	Freq.	Percent	Cum.
Commerce	858	15.47	15.47
Construction et Agriculture	520	9.37	24.84
Educ, Sante, Admin.	1,492	26.89	51.73
Industrie et IAA	1,259	22.69	74.42
Serv. aux part.	496	8.94	83.36
Service aux ent.	923	16.64	100.00
Total	5,548	100.00	



On observe que le secteur public se démarque comme étant le plus représenté dans notre échantillon suivi de l'industrie.

Pour la catégorie socioprofessionnelle au premier emploi (cspe) :

. tab cspe


Classe Socio-Professionnelle au premier emploi	Freq.	Percent	Cum.
Employe	1,872	33.74	33.74
P.lib,cadre,inge,prof.	784	14.13	47.87
Technicien,PI	1,095	19.74	67.61
ouvrier non qualifié	840	15.14	82.75
ouvrier qualifié	957	17.25	100.00
Total	5,548	100.00	



On observe une forte proportion d'employés dans l'échantillon qui représente un tiers de la distribution. On remarque également que les professions nécessitant le plus d'études sont les moins représentées.

Pour le nombre total d'entreprises différentes dans lequel l'individu a travaillé (nombre total d'entreprises différentes dans lequel l'individu a travaillé) :

Nombre d'entreprises différentes dans lequel l'individu a travaillé	Freq.	Percent	Cum.
1	1,590	28.66	28.66
2	1,646	29.67	58.33
3	1,196	21.56	79.88
4	562	10.13	90.01
5	305	5.50	95.51
6 ou plus	249	4.49	100.00
Total	5,548	100.00	




On remarque qu'environ 80% des individus ont travaillé dans 3 entreprises différentes ou moins dans leur vie, suggérant une certaine immobilité de cet échantillon que l'on pourrait comparer à un échantillon plus récent pour voir s'il y a des différences.

Dans l'histogramme, le 6 représente les individus ayant travaillé dans 6 entreprises différentes ou plus.

Pour le niveau de diplôme agrégé/plus haut niveau de diplôme obtenu (nivagr) :

. tab nivagr_1

Plus haut niveau de diplôme obtenu	Freq.	Percent	Cum.
Baccalauréat, Brevet ou aucun diplôme	1,605	28.93	28.93
CAP,BEP	2,026	36.52	65.45
L2,BTS,DUT	961	17.32	82.77
L3 ou plus	956	17.23	100.00
Total	5,548	100.00	




La distribution suggère que la majorité de la population de l'échantillon c'est à dire 71% de l'échantillon a atteint un niveau de diplôme supérieur, indiquant une proportion significative de personnes ayant suivi une éducation postsecondaire. Néanmoins, 'Baccalauréat, Brevet ou aucun diplôme' représente environ 29% de l'échantillon, elle mérite notre attention en raison de son impact potentiel sur la durée d'emploi en France.

Pour les entreprises rurale (rural) :

. tab rural

Travaillez-vous dans une entreprise rurale ?	Freq.	Percent	Cum.
Non	4,470	80.57	80.57
Oui	1,078	19.43	100.00
Total	5,548	100.00	




On peut voir qu' environ 80% des individus travaille dans une entreprise urbaine. Cette répartition suggère que la durée en emploi sera surtout influencée par les conditions des zones urbaines.

Pour la taille de l'entreprise (taille) :

`. tab taille`

Taille de l'entreprise	Freq.	Percent	Cum.
10-50	1,477	26.62	26.62
50-500	1,674	30.17	56.80
< 10	1,414	25.49	82.28
>= 500	983	17.72	100.00
Total	5,548	100.00	




On remarque que l'échantillon est majoritairement composé d'individus travaillant dans des entreprises ayant moins de 500. Étant donné que la stabilité de l'emploi tend à croître avec la taille de l'entreprise, on peut s'attendre à une durée en emploi globalement modérée dans l'échantillon.

Pour la situation professionnelle au moment de l'enquête (cens) :

`. tab cens`

Etes-vous actuellement en emploi ?	Freq.	Percent	Cum.
non	1,098	19.79	19.79
oui	4,450	80.21	100.00
Total	5,548	100.00	



On remarque que l'échantillon est principalement composé d'individus en emploi au moment de l'enquête ce qui pourrait expliquer une plus longue durée en emploi.

4. Statistiques descriptives bivariées

Nous allons effectuer des statistiques bivariées et des graphiques de la relation entre la variable expliquée et les différentes variables explicatives.


Avec les variables d'intérêt :

- durée-âge (age) :

```
. pwcorr duree age, sig
```

	duree	age
duree	1.0000	
age	0.1543 0.0000	1.0000

Le coefficient de corrélation entre la durée et l'âge est de 0.1543 et la p-value est arrondie à 0, ce qui veut dire que la corrélation entre durée et âge est significative.




Le graphique montre que la durée moyenne en emploi augmente avec l'âge. On peut donc conclure qu'il existe une relation positive modérée entre l'âge et la durée moyenne en emploi. Par conséquent, il faudra choisir un ajustement linéaire.

- durée-salaire (salcalc) :

```
. pwcorr duree salcalc, sig
```

	duree	salcalc
duree	1.0000	
salcalc	0.2572	1.0000
	0.0000	


Le coefficient de corrélation entre la durée et l'âge est de 0.2572 et la p-value est arrondie à 0, ce qui veut dire que la variable est significative.



Plus le salaire augmente, plus la durée moyenne tend à croître. Cependant, la courbe de régression quadratique (en vert) suggère un ralentissement de la progression à partir d'un certain niveau de salaire, indiquant que l'effet du salaire sur la durée moyenne pourrait diminuer aux niveaux les plus élevés. On prendra donc la forme quadratique.


Avec les variables de contrôle :

- durée-sexe (sex) :




La durée moyenne en emploi entre les hommes et les femmes est assez proche, avec une durée moyenne pour les femmes légèrement supérieure.

- durée-catégorie socioprofessionnelle de l'employeur / secteur d'activité (nes16) :




On observe que la durée moyenne en emploi des individus en fonction de la CSP de l'employeur se rapproche des 30 mois. On peut noter une durée plus courte pour le secteur du service aux particuliers.

- durée-niveau de diplôme agrégé (nivagr) :




La durée moyenne en emploi tend à augmenter avec le niveau de diplôme.
Les diplômés du supérieur (L2, BTS, DUT, L3 ou plus) restent en emploi plus longtemps, alors que les moins diplômés connaissent des emplois plus courts ou précaires.
Le niveau de qualification semble donc favoriser la pérennité de l'emploi.

- durée-catégorie socioprofessionnelle au premier emploi (cspe) :



La durée moyenne en emploi varie selon la catégorie socioprofessionnelle. Les cadres, ingénieurs et professions intellectuelles présentent une durée moyenne plus longue, tandis que les ouvriers et employés ont une stabilité professionnelle plus faible. Cela suggère que la stabilité de l'emploi augmente avec le statut professionnel.


- durée-milieu de l'entreprise (rural) :



Le graphique montre que la durée moyenne en emploi est légèrement plus élevée chez les personnes ne travaillant pas dans une entreprise rurale que chez celles travaillant dans une entreprise rurale.

On peut donc conclure qu'il existe une différence modérée de durée moyenne selon le type d'entreprise.


- durée-nombre totale d'entreprises différentes (nbent) :



Le graphique montre que la durée moyenne en emploi est très élevée pour les individus étant dans leur première entreprise et diminue lorsque le nombre d'entreprises augmente. Notre intuition de départ est confirmée avec ce graphique, plus l'individu a travaillé dans différentes entreprises, moins la durée moyenne en emploi dans une entreprise est importante. On peut noter que l'effet n'est pas linéaire puisque la durée moyenne en emploi diminue de moins en moins vite.


-

- durée-taille de l'entreprise par tranche (taille) :



La durée moyenne en emploi augmente avec la taille de l'entreprise. Les salariés des grandes entreprises (500 salariés et plus) restent en poste plus longtemps, tandis que ceux des petites entreprises (moins de 10 salariés) ont une durée moyenne d'emploi plus courte. Cela traduit une plus grande stabilité de l'emploi dans les structures de grande taille.

- durée-situation professionnelle (cens) :



Les personnes actuellement en emploi ont une durée moyenne plus élevée, indiquant une plus grande stabilité professionnelle que celles sans emploi.

PARTIE 2 : Estimation du modèle linéaire multiple

1. Présentation du modèle à estimer et le modèle estimé :

Le modèle à estimer :

$$y = a_0 + a_1x_1 + a_2x_2 + a_3x_3 + a_4x_4 + a_5x_5 + a_6x_6 + a_7x_7 + a_8x_8 + a_9x_9 + a_{10}x_{10} + a_{11}x_{11} \dots + u_i$$

Où y représente la durée en emploi, x_1 représente l'âge, x_2 représente le salaire, x_3 représente le salaire au carré, x_4 représente le sexe, x_5 représente le secteur d'activité, x_6 représente le diplôme, x_7 représente la CSPE catégorie socioprofessionnelle, x_8 représente le milieu rural, x_9 représente le nombre total d'entreprises différentes, x_{10} représente la taille de l'entreprise, x_{11} représente la situation professionnelle, a_0 est la constante, a_i sont les coefficients des variables explicatives, u_i représente les variables omises non mesurables.

Les hypothèses retenues pour l'estimation du modèle linéaire multiple sont :

H1 : Linéarité du modèle : On suppose que la relation peut être approximée par une fonction linéaire dans ses paramètres ($a_1, a_2, a_3, a_4, a_5, a_6, a_7, a_8, a_9, a_{10}, a_{11}$). Sinon on ne peut pas estimer le modèle.

H2 : Exogénéité des variables : Ici, certaines variables comme le salaire ou le diplôme pourraient être partiellement déterminées par une variable omise (comme le milieu social de l'individu). Par conséquent, les coefficients associés au salaire ne peuvent pas être interprétés comme des liens de causalité pure, en raison d'un probable biais de variable omise.

H3 : Absence de colinéarité parfaite entre les variables explicatives du modèle : Aucune variable explicative (par exemple, l'âge) n'est la copie exacte ou une combinaison parfaite d'une autre.

H4 : Homoscédasticité et absence d'autocorrélation des termes d'erreurs : La variance du terme d'erreur est constante pour toutes les observations. La dispersion des erreurs (résidus) est la même quel que soit le niveau de la durée en emploi. Les termes d'erreur sont indépendants les uns des autres. Les perturbations comme les capacités intrinsèques d'un individu i sont indépendantes de celles d'un individu j .

Le modèle estimé :

$$\hat{y}_i = \hat{a}_0 + \hat{a}_1x_1 + \hat{a}_2x_2 + \hat{a}_3x_3 + \hat{a}_4x_4 + \hat{a}_5x_5 + \hat{a}_6x_6 + \hat{a}_7x_7 + \hat{a}_8x_8 + \hat{a}_9x_9 + \hat{a}_{10}x_{10} + \hat{a}_{11}x_{11} + u_i$$

Comme H2 n'est pas vérifiée et nous n'avons pas la normalité des erreurs, les résultats obtenus à partir des tests seraient biaisés. On supposera que pour la suite de l'étude, H2 est vérifié et la normalité des erreurs aussi.

2. Résultats des estimations du modèle MCO :

* **La 1ère régression** consiste à estimer l'impact de nos variables d'intérêt (ici, c'est l'âge et le salaire), celle qui nous intéresse le plus étant donnée la problématique de l'étude :

$$y_i = \alpha_0 + \alpha_1 \text{âge} + \alpha_2 \text{salaire} + \alpha_3 \text{salaire}^2$$

```
. reg duree age salcalc salcalc2
```

Source	SS	df	MS	Number of obs	=	5,548
Model	158727.341	3	52909.1138	F(3, 5544)	=	153.32
Residual	1913143.82	5,544	345.083662	Prob > F	=	0.0000
				R-squared	=	0.0766
				Adj R-squared	=	0.0761
Total	2071871.16	5,547	373.512018	Root MSE	=	18.576

duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
age	.3277818	.1171794	2.80	0.005	.0980642	.5574993
salcalc	3.86295	.3186759	12.12	0.000	3.23822	4.487679
salcalc2	-.1439725	.0189961	-7.58	0.000	-.1812124	-.1067327
_cons	1.108368	3.669761	0.30	0.763	-6.085802	8.302538

$$\partial(y) / \partial \text{âge} = 0,3277818$$

Pour âge : D'après le tableau, nous avons 0,5% de chance de se tromper en rejetant H0 selon les p-values, ainsi nous rejetons H0, soit l'âge exerce une influence significative sur la durée en emploi des individus

$$\partial(y) / \partial \text{salaire} = 3.86295 - 2 * 0.1439725 * \text{salaire} = 0 \quad \text{alors } \text{salaire}^* = 13.41$$

Pour le salaire : D'après le tableau, nous avons 0% de chance de se tromper en rejetant H0 selon les p-values, ainsi nous rejetons H0, soit le salaire et le salaire² exercent une influence significative sur la durée en emploi des individus. Le rendement du salaire est croissant à taux croissant jusqu'à salaire= 13,41, puis décroissant (bien que cela ne concerne que peu d'individus).

On intègre ensuite progressivement les variables explicatives par "grands groupes", on commence par intégrer les variables liés à l'individu (sexe, diplôme, CSPE, nombre d'entreprises dans lequel l'individu a travaillé et situation professionnelle) : femme ; Baccalauréat ou moins ; employés ; 1 ; pas en emploi sont les modalités de références de leurs variables respectives.

. reg duree age salcalc salcalc2 i.sex_num i.nivagr_num3 i.cspe_num i.nbent_bis i.cens						
Source	SS	df	MS	Number of obs	=	5,548
Model	859203.645	17	50541.3909	F(17, 5530)	=	230.48
Residual	1212667.52	5,530	219.288882	Prob > F	=	0.0000
				R-squared	=	0.4147
				Adj R-squared	=	0.4129
Total	2071871.16	5,547	373.512018	Root MSE	=	14.808

	duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
	age	.6461485	.1269222	5.09	0.000	.3973311	.8949658
	salcalc	3.025309	.2843177	10.64	0.000	2.467934	3.582683
	salcalc2	-.1053069	.0164415	-6.40	0.000	-.1375387	-.073075
	sex_num						
	Homme	-4.890987	.4730539	-10.34	0.000	-5.818358	-3.963615
	nivagr_num3						
	CAP,BEP	.4114284	.5191013	0.79	0.428	-.6062143	1.429071
	L2,BTS,DUT	1.146025	.6864697	1.67	0.095	-.1997251	2.491776
	L3 ou plus	-4.450471	.9896409	-4.50	0.000	-6.390556	-2.510385
	cspe_num						
	P.lib,cadre,inge,prof.	-2.703196	.9672739	-2.79	0.005	-4.599433	-.8069592
	Technicien,PI	-1.288569	.6404777	-2.01	0.044	-2.544157	-.0329812
	ouvrier non qualifié	-.8401617	.6672697	-1.26	0.208	-2.148273	.4679493
	ouvrier qualifié	.4272979	.6676333	0.64	0.522	-.8815257	1.736121
	nbent_bis						
	2	-13.86885	.5217937	-26.58	0.000	-14.89177	-12.84593
	3	-21.44142	.5684813	-37.72	0.000	-22.55586	-20.32697
	4	-24.87614	.731736	-34.00	0.000	-26.31063	-23.44165
	5	-28.34586	.92941	-30.50	0.000	-30.16787	-26.52385
	6 ou plus	-31.81885	1.013629	-31.39	0.000	-33.80596	-29.83174
	cens						
	En emploi	9.100433	.5539537	16.43	0.000	8.014466	10.1864
	_cons	5.322243	4.054916	1.31	0.189	-2.626986	13.27147

Les variables "sexe_num", "nbent_bis" et "cens" sont significativement différentes de 0 au seuil de 5% ; un homme a une durée en emploi inférieure de 4 mois par rapport à une femme (selon le tableau, on peut trouver -4,8. C'est-à-dire un homme a une durée en emploi inférieur de 4 mois par rapport à une femme toutes choses égales par ailleurs). "nivagr_num", "cspe_num" ont des modalités avec des p values supérieures à 0,05 donc on les regroupera par la suite pour avoir des variables significativement différentes de 0.

Puis on intègre les variables liées à l'entreprise (secteur d'activité, entreprise rurale et la taille de l'entreprise par tranche) : Commerce, Pas rural, 10 à 50 employés sont les modalités de références de leurs variables respectives.

. reg duree age salcalc salcalc2 i.sex_num i.nivagr_num3 i.cspe_num i.nbent_bis i.cens i.nes16fusion_num i.cspe_num i.rural i.taille_num2									
Source	SS	df	MS	Number of obs	=	5,548			
				F(26, 5521)	=	153.27			
Model	868551.488	26	33405.8265	Prob > F	=	0.0000			
Residual	1203319.67	5,521	217.95321	R-squared	=	0.4192			
				Adj R-squared	=	0.4165			
Total	2071871.16	5,547	373.512018	Root MSE	=	14.763			

	duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
	age	.6714887	.127164	5.28	0.000	.4221972	.9207801
	salcalc	2.972527	.2871007	10.35	0.000	2.409697	3.535358
	salcalc2	-.1035784	.0164679	-6.29	0.000	-.135862	-.0712948
	sex_num						
	Homme	-5.107466	.4772031	-10.70	0.000	-6.042972	-4.17196
	nivagr_num3						
	CAP,BEP	.5013741	.5203897	0.96	0.335	-.5187946	1.521543
	L2,BTS,DUT	1.352822	.6888486	1.96	0.050	.002407	2.703236
	L3 ou plus	-4.135242	.9911313	-4.17	0.000	-6.07825	-2.192235
	cspe_num						
	P.lib,cadre,inge,prof.	-2.309288	.9784613	-2.36	0.018	-4.227457	-.3911185
	Technicien,PI	-1.159557	.6446106	-1.80	0.072	-2.423247	.1041341
	ouvrier non qualifié	-.9088236	.7428869	-1.22	0.221	-2.365174	.5475272
	ouvrier qualifié	.4700877	.708698	0.66	0.507	-.9192395	1.859415
	nbent_bis						
	2	-13.78183	.5212606	-26.44	0.000	-14.80371	-12.75996
	3	-21.33019	.5682449	-37.54	0.000	-22.44417	-20.2162
	4	-24.84133	.7305937	-34.00	0.000	-26.27358	-23.40908
	5	-28.38342	.9284957	-30.57	0.000	-30.20363	-26.5632
	6 ou plus	-31.57874	1.012883	-31.18	0.000	-33.56439	-29.59309
	cens						
	En emploi	8.978659	.5541311	16.20	0.000	7.892344	10.06497
	nes16fusion_num						
	Construction et Agriculture	-.8922138	.8721557	-1.02	0.306	-2.601982	.8175549
	Educ, Sante, Admin.	-3.16211	.6782727	-4.66	0.000	-4.491792	-1.832429
	Industrie et IAA	-3.136157	.7050413	-4.45	0.000	-4.518315	-1.753998
	Serv. aux part.	-1.80419	.8552992	-2.11	0.035	-3.480914	-.1274673
	Service aux ent.	-3.472704	.7192584	-4.83	0.000	-4.882734	-2.062675
	rural						
	Rural	.6030043	.5203369	1.16	0.247	-.417061	1.62307
	taille_num2						
	50-500	1.454868	.5358732	2.71	0.007	.4043458	2.505391
	500 et +	1.264659	.6439886	1.96	0.050	.0021874	2.52713
	moins de 10	-.0650429	.56385	-0.12	0.908	-1.170411	1.040325
	_cons	6.356356	4.114598	1.54	0.122	-1.709875	14.42259

On supprime la variable rural car elle est non significativement différente de 0 puis on regroupe les modalités des variables ayant des p values supérieur à 0,05 de manière à avoir seulement des variables significativement différentes de 0 (ex : après avoir regroupé cspe, on a retrouvé une variable non significative donc on l'a retiré). On se retrouve donc avec :

```
. reg duree age salcalc salcalc2 i.sex_num i.nivagr_fusion2 i.nbent_bis i.cens i.nes16fusion_num2000 i.taille_num200
```

Source	SS	df	MS	Number of obs	=	5,548
Model	864311.128	16	54019.4455	F(16, 5531)	=	247.43
Residual	1207560.03	5,531	218.325806	Prob > F	=	0.0000
				R-squared	=	0.4172
				Adj R-squared	=	0.4155
Total	2071871.16	5,547	373.512018	Root MSE	=	14.776

duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
age	.6835565	.1124307	6.08	0.000	.4631482	.9039648
salcalc	3.060844	.278062	11.01	0.000	2.515733	3.605955
salcalc2	-.1123448	.0159515	-7.04	0.000	-.1436159	-.0810737
sex_num						
Homme	-5.174125	.4344495	-11.91	0.000	-6.025817	-4.322434
nivagr_fusion2						
L3 ou plus	-5.900292	.7673299	-7.69	0.000	-7.40456	-4.396023
nbent_bis						
2	-13.81871	.5209322	-26.53	0.000	-14.83994	-12.79748
3	-21.31	.5678406	-37.53	0.000	-22.42319	-20.19681
4	-24.88631	.7296589	-34.11	0.000	-26.31673	-23.45589
5	-28.37517	.9267069	-30.62	0.000	-30.19188	-26.55846
6 ou plus	-31.66411	1.01213	-31.28	0.000	-33.64828	-29.67994
cens						
En emploi	9.082272	.5524292	16.44	0.000	7.999294	10.16525
nes16fusion_num2000						
Educ,Sante,Admin.	-2.60013	.5668268	-4.59	0.000	-3.711333	-1.488927
Industrie et IAA	-2.456663	.5623162	-4.37	0.000	-3.559023	-1.354302
Service au ent.	-2.737512	.6190076	-4.42	0.000	-3.951011	-1.524014
taille_num200						
50-500	1.470099	.4724149	3.11	0.002	.54398	2.396218
500 et +	1.314797	.5948573	2.21	0.027	.1486434	2.480952
_cons	5.348097	3.467875	1.54	0.123	-1.4503	12.14649

Le R² corrigé est de 0.4155, 41.55% de la variance des salaires est expliquée par les variables du modèle. Toutes les variables explicatives sont significativement différentes de 0.

3. Commentaire des résultats :

Test de significativité globale de la régression ou test de Fisher

Les modalités de référence sont : femme ; L2 ou moins ; nombre d'entreprise 1 ; pas en emploi ; Commerce, construction et agriculture ; 50 ou moins.

```
. reg duree age salcalc salcalc2 i.sex_num i.nivagr_fusion2 i.nbent_bis i.cens i.nes16fusion_num2000 i.taille_num200
```

Source	SS	df	MS	Number of obs	=	5,548
Model	864311.128	16	54019.4455	F(16, 5531)	=	247.43
Residual	1207560.03	5,531	218.325806	Prob > F	=	0.0000
				R-squared	=	0.4172
				Adj R-squared	=	0.4155
Total	2071871.16	5,547	373.512018	Root MSE	=	14.776

duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
age	.6835565	.1124307	6.08	0.000	.4631482	.9039648
salcalc	3.060844	.278062	11.01	0.000	2.515733	3.605955
salcalc2	-.1123448	.0159515	-7.04	0.000	-.1436159	-.0810737
sex_num						
Homme	-5.174125	.4344495	-11.91	0.000	-6.025817	-4.322434
nivagr_fusion2						
L3 ou plus	-5.900292	.7673299	-7.69	0.000	-7.40456	-4.396023
nbent_bis						
2	-13.81871	.5209322	-26.53	0.000	-14.83994	-12.79748
3	-21.31	.5678406	-37.53	0.000	-22.42319	-20.19681
4	-24.88631	.7296589	-34.11	0.000	-26.31673	-23.45589
5	-28.37517	.9267069	-30.62	0.000	-30.19188	-26.55846
6 ou plus	-31.66411	1.01213	-31.28	0.000	-33.64828	-29.67994
cens						
En emploi	9.082272	.5524292	16.44	0.000	7.999294	10.16525
nes16fusion_num2000						
Educ,Sante,Admin.	-2.60013	.5668268	-4.59	0.000	-3.711333	-1.488927
Industrie et IAA	-2.456663	.5623162	-4.37	0.000	-3.559023	-1.354302
Service au ent.	-2.737512	.6190076	-4.42	0.000	-3.951011	-1.524014
taille_num200						
50-500	1.470099	.4724149	3.11	0.002	.54398	2.396218
500 et +	1.314797	.5948573	2.21	0.027	.1486434	2.480952
_cons	5.348097	3.467875	1.54	0.123	-1.4503	12.14649

```
. display (0.4172/16)/((1-0.4172)/5531)
247.46195
```

Intuition : La régression est globalement significative car $F * 247.46$ (assez grand) $> F * \alpha$ (sous stata, on a trouvé 247.43), on rejette H_0 : la régression est globalement significative, il y a au moins une variable qui explique significativement y.

($F * \alpha$ pour $\alpha = 5\%$ est compris entre 2,18 et 1,79 selon la table statistique)

Test de significativité de chacun des coefficients

```
. display (0.6835565/0.1124307)
6.0798029
```

Pour l'âge : Le coefficient est de 0.68 avec une p-value de 0.000 ($t = 6.08$). Nous rejetons H_0 car $6,08 > 1,96$, la variable est significative. Contrairement au salaire, ici la relation est linéaire. Ainsi : $\delta_{\text{duree}} / \delta_{\text{age}} = 0.68$. Le rendement de l'âge est donc constant et positif. Toutes choses égales par ailleurs, une année d'âge supplémentaire augmente la durée en emploi de 0,68 mois (soit environ 20 jours). Plus l'individu est âgé, plus sa durée en emploi est longue.

```
. display (3.060844)/(2*0.1123448)
13.622544
```

Pour le salaire : $t = 11,01 > 7,04 > 1,96$ donc salaire et salaire au carré sont significatives

$\delta_{\text{duree}} / \delta_{\text{salaire}} = 3.060844 - 2 * 0.1123448 * \text{salaire} = 0$, alors $\text{salaire}^* = 13,62$. L'effet de salaire sur la durée est croissant à taux décroissant. Il est croissant jusqu'à $\text{salaire} = 13,62$, puis décroissant par la suite. Intuitivement, plus un salaire est élevé, plus un individu est enclin à garder son emploi. L'effet négatif pourrait s'expliquer par des opportunités d'emploi plus importantes ou des responsabilités trop importantes qui incitent l'individu à changer d'emploi.

Pour le sexe :

```
. display (-5.174125/0.4344495)
-11.909612
```

Intuition : On recalcule la statistique de student ($T(5548-16-1)$) à la main pour la variable homme, on a trouvé -11,9096 (sous stata, on a trouvé -11,91). Avec un risque d'erreur de 5%, $-t^* = -1,96$. Comme $|t| > 1,96$, on rejette H_0 avec un risque d'erreur de 5% ; le coefficient est significativement différent de 0 ; la variable homme(sexe) influence significativement le salaire. De même, d'après le tableau sous stata (les colonnes t et p-values), nous pouvons en conclure que toutes les variables que nous avons choisies influencent significativement la durée en emploi. Toutes choses égales par ailleurs, en moyenne, un homme a une durée en emploi inférieure de 5 mois par rapport à une femme.

Pour le reste des variables explicatives, leur $|t|$ de student est supérieur à 1,96 donc les variables explicatives sont significativement différentes de 0.

Pour le diplôme, un individu ayant un diplôme niveau L3 ou plus a en moyenne, toute chose égale par ailleurs, une durée en emploi inférieure de 5 mois par rapport à un individu ayant un diplôme de niveau L2 ou moins.

En ce qui concerne le nombre d'entreprises, toutes choses égales par ailleurs, par rapport à un individu n'ayant travaillé que dans une seule entreprise (référence), en moyenne, un

individu ayant travaillé dans 2 entreprises voit a une durée en emploi inférieur de 13 mois. De même, un individu ayant travaillé dans 3 entreprises a une durée inférieure de 21 mois, et celui en ayant fait 4 a une durée inférieure de 24 mois. L'effet négatif s'amplifie avec le nombre d'entreprises : un individu ayant travaillé dans 5 entreprises a une durée réduite de 28 mois, et pour 6 entreprises ou plus, la durée est inférieure de 31 mois par rapport à la référence. L'effet important du nombre d'entreprises peut s'expliquer par un effet mécanique.

Pour la situation professionnelle, toutes choses égales par ailleurs, en moyenne, le fait d'être "En emploi" augmente la durée de 9 mois par rapport aux individus qui ne sont pas en emploi.

Concernant le secteur d'activité, par rapport au secteur de référence ("Commerce, Construction et Agriculture"), toutes choses égales par ailleurs, en moyenne, travailler dans l'Éducation/Santé diminue la durée de 2 mois, dans l'Industrie de 2 mois et dans les Services aux entreprises de 2 mois.


Enfin, pour la taille de l'entreprise, toutes choses égales par ailleurs, en moyenne, travailler dans une entreprise moyenne (50-500 salariés) augmente la durée de 1 mois, et dans une grande entreprise (500 et +) de 1 mois par rapport aux petites entreprises (moins de 50).

On obtient les résultats attendus dans toutes nos variables explicatives.

```
. display (864311.128/2071871.16)  
.41716452
```

La qualité d'ajustement donnée par le tableau est de $R^2 = 0.4172$ (similaire au résultat de notre calcul 0.41716), ce qui signifie que le modèle explique environ 41.72% de la variabilité de la durée.

4. Tests de détection de l'hétéroscédasticité :



Observation :

Le nuage de points des résidus ne forme pas un rectangle uniforme autour de l'axe 0. On observe que les résidus sont **contenus entre deux droites qui décroissent** : la dispersion est forte pour les faibles durées d'emploi et se réduit considérablement pour les durées élevées. Ce resserrement de la variance indique que la variance de l'erreur n'est pas constante. Cela laisse suspecter une **hétéroscédasticité** des erreurs.

Test de Goldfeld-Quandt

```
. reg duree age salcalc salcalc2 i.sex_num i.nivagr_fusion2 i.nbent_bis i.cens i.nes16fusion_num2000 i.taille_num200 if _n<=2081
```

Source	SS	df	MS	Number of obs	=	2,081
Model	317698.12	16	19856.1325	F(16, 2064)	=	98.35
Residual	416694.286	2,064	201.886766	Prob > F	=	0.0000
				R-squared	=	0.4326
				Adj R-squared	=	0.4282
Total	734392.406	2,080	353.073272	Root MSE	=	14.209

duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
age	.4334044	.1720114	2.52	0.012	.0960705	.7707384
salcalc	2.924355	.4181046	6.99	0.000	2.104404	3.744305
salcalc2	-.0901475	.021836	-4.13	0.000	-.1329704	-.0473245
sex_num						
Homme	-4.805428	.6701269	-7.17	0.000	-6.119624	-3.491233
nivagr_fusion2						
L3 ou plus	-5.352103	1.142317	-4.69	0.000	-7.592317	-3.111889
nbent_bis						
2	-13.82604	.8017525	-17.24	0.000	-15.39836	-12.25371
3	-21.78663	.8859136	-24.59	0.000	-23.524	-20.04925
4	-25.5794	1.208748	-21.16	0.000	-27.94989	-23.20891
5	-27.04914	1.48306	-18.24	0.000	-29.95759	-24.14069
6 ou plus	-30.29111	1.74807	-17.33	0.000	-33.71928	-26.86295
cens						
En emploi	8.463012	.9090859	9.31	0.000	6.680191	10.24583
nes16fusion_num2000						
Educ,Sante,Admin.	-2.982279	.9243343	-3.23	0.001	-4.795004	-1.169554
Industrie et IAA	-2.45453	.8991471	-2.73	0.006	-4.21786	-.6911998
Service au ent.	-2.771624	.9731732	-2.85	0.004	-4.680128	-.863121
taille_num200						
50-500	.8461504	.7454841	1.14	0.256	-.6158289	2.30813
500 et +	.4371801	.9025034	0.48	0.628	-1.332732	2.207092
_cons	12.10345	5.353811	2.26	0.024	1.604013	22.60288

```
. scalar df1=e(df_r)
```

```
. scalar scr1=e(rss)
```

```
. reg duree age salcalc salcalc2 i.sex_num i.nivagr_fusion2 i.nbent_bis i.cens i.nes16fusion_num2000 i.taille_num200 if _n>=3468
```

Source	SS	df	MS	Number of obs	=	2,081
Model	329573.256	16	20598.3285	F(16, 2064)	=	93.16
Residual	456340.857	2,064	221.095376	Prob > F	=	0.0000
				R-squared	=	0.4194
				Adj R-squared	=	0.4148
Total	785914.113	2,080	377.843324	Root MSE	=	14.869

duree	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
age	.5995581	.1979976	3.03	0.002	.2112622	.9878539
salcalc	3.009932	.529686	5.68	0.000	1.971158	4.048707
salcalc2	-.1208877	.032299	-3.74	0.000	-.1842297	-.0575456
sex_num						
Homme	-5.281044	.7182895	-7.35	0.000	-6.689692	-3.872396
nivagr_fusion2						
L3 ou plus	-4.468641	1.133782	-3.94	0.000	-6.692117	-2.245164
nbent_bis						
2	-13.06424	.8740091	-14.95	0.000	-14.77827	-11.35021
3	-21.81085	.9366739	-23.29	0.000	-23.64777	-19.97391
4	-25.37755	1.157657	-21.92	0.000	-27.64785	-23.10725
5	-29.9764	1.541574	-19.45	0.000	-32.9996	-26.95311
6 ou plus	-32.61568	1.59825	-20.41	0.000	-35.75003	-29.48131
cens						
En emploi	9.755395	.9694124	10.06	0.000	7.854267	11.65651
nes16fusion_num2000						
Educ,Sante,Admin.	-1.425629	.9202621	-1.55	0.121	-3.230368	.3791091
Industrie et IAA	-.7830317	.9603883	-0.82	0.415	-2.666463	1.100391
Service au ent.	-1.091537	.9929822	-1.10	0.272	-3.038888	.8558141
taille_num200						
50-500	1.906166	.7674518	2.48	0.013	.4011058	3.411221
500 et +	1.194256	.9559098	1.25	0.212	-.6803919	3.068904
_cons	8.689143	6.420919	1.35	0.176	-3.903011	21.2813

```
. scalar df2=e(df_r)
. scalar scr2=e(rss)
. scalar GQ = (scr2/df2)/(scr1/df1)
. scalar pv =Ftail(df1,df2,GQ)
. dis GQ
1.0951455
. dis pv
.01951098
```

Conclusion : Le test consiste à calculer le rapport de ces 2 variances qui, sous l'hypothèse nulle d'homoscédasticité, suit un rapport de χ^2 , c'est-à-dire une loi de Fisher. En pratique, on compare la somme des carrés des résidus de ces 2 sous-modèles, et la statistique de test est la suivante : $F^* = SCR2/ddl2 \text{ } SCR1/ddl1 \rightarrow F(ddl1, ddl2)$.

Sur le 1er échantillon : $SCR1 = 416694,286$ et $ddl1 = N - k - 1 = 2081 - 16 - 1 = 2064$
 Sur le 2ème échantillon : $SCR2 = 456340.857$ et $ddl2 = N - k - 1 = 2081 - 16 - 1 = 2064$
 $F^* = SCR2/ddl2 \text{ } SCR1/ddl1 = 1.095 \rightarrow F(2064,2064)$. Or, la valeur tabulée d'une F (2064,2064) pour un risque de 1ère espèce de 5% est environ $1 < 1,095$.

Par ailleurs, Stata donne la p-value = 0.0195 (soit 1,95 %).

Or, cette p-value est inférieure au seuil de risque de 5% ($0.0195 < 0.05$).

Donc, **on rejette l'hypothèse d'homoscédasticité**. Les variances des deux sous-échantillons sont significativement différentes.

Test de Gleisjer

Nous effectuons ce test manuellement en régressant la valeur absolue des résidus sur les variables explicatives

```
. reg abs_res age
```

Source	SS	df	MS	Number of obs	=	5,548
Model	443.811126	1	443.811126	F(1, 5546)	=	6.22
Residual	396000.051	5,546	71.402822	Prob > F	=	0.0127
				R-squared	=	0.0011
				Adj R-squared	=	0.0009
Total	396443.862	5,547	71.4699588	Root MSE	=	8.45

abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
age	-.1149222	.0460959	-2.49	0.013	-.2052883	-.0245561
_cons	15.74777	1.471009	10.71	0.000	12.86402	18.63153

```
. reg abs_res age1nv
```

Source	SS	df	MS	Number of obs	=	5,548
Model	590.055399	1	590.055399	F(1, 5546)	=	8.27
Residual	395853.806	5,546	71.3764526	Prob > F	=	0.0041
				R-squared	=	0.0015
				Adj R-squared	=	0.0013
Total	396443.862	5,547	71.4699588	Root MSE	=	8.4485

abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
age1nv	140.9073	49.00771	2.88	0.004	44.83293	236.9816
_cons	7.637551	1.553169	4.92	0.000	4.592731	10.68237

```
. reg abs_res age1sqrt
```

Source	SS	df	MS	Number of obs	=	5,548
Model	481.471148	1	481.471148	F(1, 5546)	=	6.74
Residual	395962.391	5,546	71.3960315	Prob > F	=	0.0094
				R-squared	=	0.0012
				Adj R-squared	=	0.0010
Total	396443.862	5,547	71.4699588	Root MSE	=	8.4496

abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
age1sqrt	-1.37216	.5283924	-2.60	0.009	-2.408016	-.3363036
_cons	19.82557	2.980474	6.65	0.000	13.98267	25.66846

```
.
```

```
. reg abs_res age1nvsqrt
```

Source	SS	df	MS	Number of obs	=	5,548
Model	554.812832	1	554.812832	F(1, 5546)	=	7.77
Residual	395889.049	5,546	71.3828072	Prob > F	=	0.0053
				R-squared	=	0.0014
				Adj R-squared	=	0.0012
Total	396443.862	5,547	71.4699588	Root MSE	=	8.4488

abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
age1nvsqrt	48.0277	17.22723	2.79	0.005	14.25559	81.79981
_cons	3.558533	3.062753	1.16	0.245	-2.445662	9.562728

L'hypothèse

d'homoscédasticité est rejetée

si le coefficient d'une des

spécifications est

significativement différent de

0. Les quatre valeurs absolu

|t| de student empiriques sont

supérieur à 1,96 (pour un seuil

de 5%), on rejette H0,

l'hétéroscédasticité est

donc détectée.

On va maintenant tester la variable salaire.

```
. reg abs_res salcalc
```

Source	SS	df	MS	Number of obs	=	5,548
Model	952.761966	1	952.761966	F(1, 5546)	=	13.36
Residual	395491.1	5,546	71.311053	Prob > F	=	0.0003
				R-squared	=	0.0024
				Adj R-squared	=	0.0022
Total	396443.862	5,547	71.4699588	Root MSE	=	8.4446

abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
salcalc	-.1396069	.0381938	-3.66	0.000	-.2144817	-.064732
_cons	13.04428	.2842983	45.88	0.000	12.48694	13.60161

```
. reg abs_res salcalclin
```

Source	SS	df	MS	Number of obs	=	5,548
Model	185.481048	1	185.481048	F(1, 5546)	=	2.60
Residual	396258.381	5,546	71.4494015	Prob > F	=	0.1072
				R-squared	=	0.0005
				Adj R-squared	=	0.0003
Total	396443.862	5,547	71.4699588	Root MSE	=	8.4528

abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
salcalclin	1.915974	1.189157	1.61	0.107	-.4152393	4.247187
_cons	11.7445	.2433309	48.27	0.000	11.26748	12.22152

```
. reg abs_res salcalcisqrt
```

Source	SS	df	MS	Number of obs	=	5,548
Model	766.124818	1	766.124818	F(1, 5546)	=	10.74
Residual	395677.737	5,546	71.3447055	Prob > F	=	0.0011
				R-squared	=	0.0019
				Adj R-squared	=	0.0018
Total	396443.862	5,547	71.4699588	Root MSE	=	8.4466

abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
salcalcisqrt	-.6595211	.2012611	-3.28	0.001	-1.054072	-.2649705
_cons	13.77388	.5258306	26.19	0.000	12.74304	14.80471

.

```
. reg abs_res salcalclinvsqrt
```

Source	SS	df	MS	Number of obs	=	5,548
Model	337.106413	1	337.106413	F(1, 5546)	=	4.72
Residual	396106.755	5,546	71.4220619	Prob > F	=	0.0299
				R-squared	=	0.0009
				Adj R-squared	=	0.0007
Total	396443.862	5,547	71.4699588	Root MSE	=	8.4512

abs_res	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
salcalclinvsqrt	2.438055	1.122215	2.17	0.030	.2380733	4.638037
_cons	11.08375	.4774477	23.21	0.000	10.14777	12.01973

L'hypothèse d'homoscédasticité est rejetée si le coefficient d'une des spécifications est significativement différent de 0. Les quatre t de student empiriques sont supérieur à 1,96(pour un seuil de 5%), on rejette H0, l'hétéroscédasticité est détectée. **Donc, on rejette l'hypothèse d'homoscédasticité.**

Test de Breusch-Pagan

```
. reg res2 age salcalc salcalc2 i.sex_num i.nivagr_fusion2 i.nbent_bis i.cens i.nes16fusion_num2000 i.taille_num200
```

Source	SS	df	MS	Number of obs	=	5,548
Model	12847957	16	802997.313	F(16, 5531)	=	10.80
Residual	411113078	5,531	74328.8876	Prob > F	=	0.0000
				R-squared	=	0.0303
				Adj R-squared	=	0.0275
Total	423961035	5,547	76430.6895	Root MSE	=	272.63

res2	Coefficient	Std. err.	t	P> t	[95% conf. interval]
age	-2.274459	2.074489	-1.10	0.273	-6.341272 1.792355
salcalc	-3.857829	5.130597	-0.75	0.452	-13.91582 6.200157
salcalc2	-.13759	.2943247	-0.47	0.640	-.7145821 .439402
sex_num					
Homme	-25.53697	8.016145	-3.19	0.001	-41.25177 -9.82218
nivagr_fusion2					
L3 ou plus	-5.94058	14.15821	-0.42	0.675	-33.69624 21.81508
nbent_bis					
2	-4.115818	9.611861	-0.43	0.669	-22.95884 14.72721
3	-40.9296	10.47738	-3.91	0.000	-61.46938 -20.38981
4	-88.45189	13.46313	-6.57	0.000	-114.8449 -62.05885
5	-105.131	17.09892	-6.15	0.000	-138.6516 -71.61042
6 ou plus	-125.0595	18.67508	-6.70	0.000	-161.67 -88.44897
cens					
En emploi	45.99363	10.19302	4.51	0.000	26.0113 65.97595
nes16fusion_num2000					
Educ,Sante,Admin.	-5.949633	10.45867	-0.57	0.569	-26.45274 14.55348
Industrie et IAA	-8.26392	10.37545	-0.80	0.426	-28.60388 12.07604
Service au ent.	-12.36138	11.42148	-1.08	0.279	-34.75196 10.0292
taille_num200					
50-500	10.63344	8.716655	1.22	0.223	-6.454631 27.72151
500 et +	-4.844683	10.97587	-0.44	0.659	-26.36171 16.67234
_cons	335.873	63.9867	5.25	0.000	210.4339 461.3121

```
. testparm i.sex_num i.nivagr_fusion2 i.nbent_bis i.cens i.nes16fusion_num2000 i.taille_num200 age salcalc salcalc2
```

```
( 1) age = 0
( 2) salcalc = 0
( 3) salcalc2 = 0
( 4) 2.sex_num = 0
( 5) 4.nivagr_fusion2 = 0
( 6) 2.nbent_bis = 0
( 7) 3.nbent_bis = 0
( 8) 4.nbent_bis = 0
( 9) 5.nbent_bis = 0
(10) 6.nbent_bis = 0
(11) 1.cens = 0
(12) 3.nes16fusion_num2000 = 0
(13) 4.nes16fusion_num2000 = 0
(14) 6.nes16fusion_num2000 = 0
(15) 2.taille_num200 = 0
(16) 3.taille_num200 = 0

F( 16, 5531) = 10.80
Prob > F = 0.0000
```

En effet $F = 10.80$ et $p = 0 < 0,05$ donc on rejette H_0 , au moins 1 des coefficients est significativement différent de 0. On a donc une suspicion d'hétéroscédasticité en fonction d'au moins une variable.

. gen LM = 5548*0.0303

. dis LM
168.1044

Via test LM : $LM = N * R^2 = 168,1044$. La valeur théorique pour un risque de 1ère espèce de 5% est $\chi^2_{0.05}(16) = 26,296$. On rejette H_0 . Nous sommes, dans les deux cas, amenés à rejeter l'hypothèse H_0 pour un seuil de 5%. **Le modèle est donc hétéroscédastique.**

Conclusion :

Notre étude visait à identifier les déterminants de la durée en emploi en utilisant un modèle de régression par les Moindres Carrés Ordinaires. Les variables explicatives incluaient l'âge, le salaire, le sexe, le niveau de diplôme agrégé, etc...

Les résultats obtenus fournissent des informations importantes pour comprendre la durée d'emploi au sein de notre population d'étude. Le modèle dans son ensemble explique environ 42% de la variation des durées.

Nous avons observé des corrélations significatives entre la durée en emploi et plusieurs variables étudiées. L'âge, le salaire (jusqu'à un certain niveau), la situation professionnelle (le fait d'être en emploi) et la taille de l'entreprise (être dans une grande entreprise) ont tous montré une relation positive avec la durée, indiquant une tendance à une durée d'emploi plus élevée avec l'expérience et la stabilité de l'environnement de travail. Inversement, être un homme, avoir un haut niveau de diplôme et avoir travaillé dans un grand nombre d'entreprises sont associés à une durée en emploi significativement plus courte.

Lors de l'analyse de l'importance relative, en observant les statistiques de test (t), il apparaît que l'historique de mobilité (nombre d'entreprises) et le statut d'emploi sont les déterminants dominants de la variation de la durée dans notre échantillon.

Les tests d'hypothèses visant à vérifier la qualité du modèle indiquent que l'hypothèse d'homoscédasticité doit être rejetée, le modèle souffre d'hétéroscédasticité. Puisque l'hétéroscédasticité a été détectée par l'ensemble des tests (Goldfeld-Quandt, Gleisjer et Breusch-Pagan), les écarts-types calculés par la méthode des MCO classiques sont biaisés. Pour garantir la validité de nos tests de Student (t-tests) et de nos intervalles de confiance, il est impératif de corriger l'hétéroscédasticité. Étant donné la très grande taille de l'échantillon ($N > 5000$), les estimateurs des coefficients restent sans biais et convergents, ce qui permet de conserver l'interprétation économique des signes et des magnitudes des coefficients.

Quant aux variables supplémentaires nécessaires pour expliquer la variation de la durée en emploi, le type de contrat (CDD, CDI, Intérim) est une variable manquante cruciale qui influence mécaniquement la durée. La situation familiale (nombre d'enfants), motivation ou les conditions de travail (pénibilité) pourraient également aider à capturer ces différences et à mieux modéliser la stabilité des individus en emploi. La variable la plus suspecte d'être endogène est le salaire. Si le salaire est endogène, l'estimateur des MCO est biaisé. Le coefficient ne peut donc plus s'interpréter comme un effet causal strict du salaire sur la durée "toutes choses égales par ailleurs", car il capture en partie l'effet inverse.